

โจทย์ที่ 2: การจำแนกข่าวด้วย TF-IDF Weighted TextCNN

Overview

ได้รับข่าวภาษาอังกฤษจาก AG News และต้องจำแนกแต่ละข่าวเป็น 4 หมวด ได้แก่ World, Sports, Business และ Sci/Tech ข้อมูลดิบมี URL, ตัวเลข, backslash, ช่องว่างไม่สม่ำเสมอ และข่าวซ้ำบางส่วน

ให้ทำความสะอาดข้อมูล สร้าง feature TF-IDF และสร้าง TextCNN ด้วย PyTorch โดยสามารถใช้ scikit-learn สำหรับการแบ่งข้อมูล การสร้าง feature TF-IDF และการวัดผลได้

Description

ข้อมูลที่ให้มาเป็นข้อมูลดิบจาก AG News ยังไม่ผ่านการทำความสะอาด ไม่มีการลบข้อความซ้ำ และไม่มีชุด validation แยกไว้ให้ ผู้ทำโจทย์ต้องทำความสะอาดข้อความ (ลบ URL, ตัวเลข, backslash, ช่องว่างที่ไม่จำเป็น) ลบข้อความซ้ำ และแบ่งข้อมูลจาก `train.csv` ออกเป็นส่วน train และ validation เอง ก่อนสร้าง TF-IDF และเทรนโมเดล โดย TF-IDF ต้อง fit จากข้อความในส่วน train ที่แบ่งแล้วเท่านั้น

- `train.csv` : ข่าวดิบ 120,000 รายการ มีคอลัมน์ `id`, `text`, `label`
- `test.csv` : ข่าวดิบ 7,600 รายการ มีคอลัมน์ `id`, `text` เท่านั้น ไม่มี `label`

คอลัมน์ `label` ใช้ค่า 0 = World, 1 = Sports, 2 = Business และ 3 = Sci/Tech

Public Data

โครงสร้างไฟล์ใน `data` :

```
train.csv
test.csv
```

`train.csv` มีคอลัมน์ `id`, `text`, `label` ส่วน `test.csv` มีเพียง `id`, `text` ลำดับแถวของ `test.csv` ตรงกับ `id` ที่ใช้ใน submission

Evaluation

ใช้ Accuracy และ Macro-F1 โดย Macro-F1 ให้น้ำหนักแต่ละคลาสเท่ากัน

```
Macro-F1 = mean(F1_World, F1_Sports, F1_Business, F1_SciTech)
```

Submission File

ส่งไฟล์ `submission_nlp.csv` จำนวน 7,600 แถว

```
id,label  
17,2  
483,0  
921,3
```

- `id` : id จาก `test.csv`
- `label` : คลาสที่ทำนาย ต้องเป็น 0, 1, 2 หรือ 3



Leagues of Code



Leagues of Code