

โจทย์ที่ 3: การพยากรณ์รังสีแสงอาทิตย์ด้วย Feature Engineering และ CatBoost

Overview

ได้รับข้อมูลสภาพอากาศและรังสีแสงอาทิตย์รายชั่วโมงของกรุงเทพฯ จาก NASA POWER ให้พยากรณ์ค่ารังสีที่วัดได้ของ ชั่วโมงถัดไป

โจทย์นี้ต้องสร้าง feature ที่สะท้อนคาบเวลา ตำแหน่งดวงอาทิตย์ และสภาพอากาศ พร้อมสรุปค่าย้อนหลัง 48 ชั่วโมง (ค่าเฉลี่ย ส่วนเบี่ยงเบนมาตรฐาน และ lag) ก่อนส่งเข้าโมเดล CatBoost

Description

ข้อมูลถูกแบ่งตามเวลาเพื่อจำลองการพยากรณ์อนาคตจริง ไฟล์ที่ให้มาเป็นข้อมูลดิบจาก NASA POWER ยังไม่ผ่านการสร้าง feature ผู้ทำโจทย์ต้องสร้าง feature เอง (cyclic time, ตำแหน่งดวงอาทิตย์, wind components เป็นต้น) ก่อนส่งเข้าโมเดล

- `train.csv` : target time ปี 2019–2022 จำนวน 35,063 แถว มีคอลัมน์ดิบและ `target`
- `validation.csv` : target time ปี 2023 จำนวน 8,760 แถว มีคอลัมน์ดิบและ `target`
- `test.csv` : target time ปี 2024 จำนวน 8,784 แถว มีคอลัมน์ดิบเดียวกันแต่ไม่มี `target`

คอลัมน์ดิบจาก NASA POWER ได้แก่ `CLRSKY_SFC_SW_DWN`, `T2M`, `T2MDEW`, `RH2M`, `PS`, `WS10M`, `WD10M`, `PRECTOTCORR` และ `CLOUD_AMT`

ทุกไฟล์มี timestamp, target time และ feature ชนิดเดียวกัน ชุด test ไม่มีค่าเป้าหมาย แต่สามารถต่อข้อมูลส่วนท้ายของ validation เข้ากับต้น test เพื่อสร้าง lookback 48 ชั่วโมงได้โดยไม่ใช้ข้อมูลอนาคต

Public Data

โครงสร้างไฟล์ใน `data/public` :

```
train.csv
validation.csv
test.csv
```

`train.csv` และ `validation.csv` มีคอลัมน์ `target` ส่วน `test.csv` ไม่มีคอลัมน์ดังกล่าว ทั้งสามไฟล์เรียงตามเวลาและต้องไม่ถูกสุ่มสลับก่อนสร้าง feature ย้อนหลัง

Evaluation

ใช้ MAE, RMSE และ R-squared โดยรายงานทั้งทุกช่วงเวลาและเฉพาะช่วงที่ค่ารังสีจริงมากกว่า 20

```
MAE = mean(abs(y_true - y_pred))  
RMSE = sqrt(mean((y_true - y_pred)^2))
```

Submission File

ส่งไฟล์ `submission_solar.csv` จำนวน 8,784 แถว

```
id,predicted_ghi  
0,0.0  
1,0.0  
2,5.7
```

- `id` : ลำดับแถวของ `test.csv`
- `predicted_ghi` : ค่ารังสีที่วัดได้ของชั่วโมงถัดไปที่โมเดลทำนาย และต้องไม่ติดลบ



Leagues of Code